Universidad del Valle de Guatemala

Facultad de Ingeniería

Departamento de Computación

Data Science

LABORATORIO VIII

ANÁLISIS DE VIAJES DE TAXI DE NUEVA YORK

André Emilio Pivaral López – 23574

Catedrático: Boris Fernando Becerra Peláez

Sección: 30

Nueva Guatemala de la Asunción, 8 de Octubre de 2026

Índice

1. Resumen **1**

2. Introducción **1**

3. Metodología **2**
3.1. Ambiente reproducible 2
3.2. Descarga incremental de los datos 2
3.3. Consultas directas y reglas de calidad 3
3.4. Preguntas de análisis 4
3.5. Diseño del benchmark 4
3.6. Indicadores y tablero 5

4. Resultados **6**
4.1. Disponibilidad y estructura de los archivos 6
4.2. Calidad de los datos 7
4.3. Análisis exploratorio de 2026 8
4.3.1. Comportamiento temporal 8
4.3.2. Diferencias entre taxis amarillos y verdes 9
4.3.3. Pago, propina y valores atípicos 11
4.4. Incorporación de 2024 11
4.5. Benchmark entre Parquet y tablas materializadas 12
4.6. Indicadores y tablero en Metabase 14
4.7. Evolución entre 2024 y 2026 17

5. Discusión **19**
5.1. Parquet directo frente a tablas materializadas 19
5.2. DuckDB frente a Pandas 19
5.3. Incorporación de datos con cambios mínimos 20
5.4. Limitaciones 20
5.5. Automatización en producción 20

6. Conclusiones **20**

7. Referencias **21**

1. Resumen

Este informe documenta la construcción de un flujo reproducible para descargar, consultar, transformar y visualizar los registros de viajes de taxis amarillos y verdes publicados por la New York City Taxi & Limousine Commission. Todo el análisis se ejecutó con DuckDB 1.5.5 directamente sobre archivos Parquet, dentro de un ambiente de Docker Compose, y los indicadores se publicaron en un tablero de Metabase. El conjunto creció en tres etapas, primero 2026, luego 2024 y finalmente 2025, hasta reunir 64 archivos con 121,184,384 registros, y ninguna consulta tuvo que modificarse al incorporar los nuevos años. Las reglas de calidad conservaron entre el 90.67 % y el 96.34 % de los registros de cada año, con la distancia cero como exclusión más frecuente. Entre 2024 y 2026 los viajes válidos por día pasaron de 110,103 a 117,495 y el total promedio por viaje de 28.56 a 30.19 dólares, mientras los taxis verdes bajaron del 1.54 % al 1.13 % de los viajes y los pagos sin registro subieron del 9.23 % al 24.83 %. En el benchmark, una tabla materializada en DuckDB redujo de 41.8 s a 19.1 s el tiempo de seis consultas sobre 71.9 millones de registros, a cambio de 93.1 s de creación y del doble de espacio en disco, un costo que se recupera en cuatro a cinco ejecuciones.

2. Introducción

La New York City Taxi & Limousine Commission, TLC, publica cada mes los registros de viajes de los taxis de la ciudad en archivos Parquet. Cada mes de taxis amarillos contiene entre tres y cinco millones de registros, por lo que tres años de datos superan los cien millones de filas. A ese volumen, cargar todos los datos en memoria con Pandas deja de ser viable en un equipo personal, y la forma en que se almacenan y se leen los datos pasa a determinar si el análisis es posible.

El laboratorio aborda ese problema con DuckDB, un motor de consultas analíticas embebido que lee Parquet directamente. Los objetivos fueron cinco:

- Preparar un ambiente reproducible con Docker Compose y un sistema de descarga incremental y verificable.
- Explorar los archivos sin importarlos, identificar sus problemas de calidad y responder preguntas de análisis con SQL.
- Incorporar nuevos años de datos sin modificar las consultas existentes.
- Comparar el desempeño de consultar los Parquet directamente frente a una tabla materializada en DuckDB.

- Construir indicadores y un tablero en Metabase, y analizar su evolución entre 2024 y 2026.

El repositorio contiene el notebook notebooks/Laboratorio8.ipynb, los scripts de descarga, benchmark e indicadores, las consultas SQL documentadas y la evidencia del tablero. Este informe resume la metodología, los resultados y la discusión, sin incluir código.

3. Metodología

3.1. Ambiente reproducible

El ambiente se define en docker-compose.yml con dos servicios. El servicio lab contiene Python 3.11.14, DuckDB 1.5.5, JupyterLab 4.6.4, pandas 3.0.6, PyArrow 25.0.1, Matplotlib 3.11.2 y Requests 2.34.2, con versiones exactas en requirements.txt. El servicio metabase contiene Metabase v0.63.19 sobre Java 21 con el controlador de DuckDB 1.5.5.0, cuya versión debe coincidir con la de DuckDB para poder abrir las bases que este escribe. JupyterLab queda disponible en el puerto 8888 y Metabase en el 3001, ambos publicados solo en la dirección local. Las carpetas data, notebooks, scripts, sql y docs se montan en /workspace dentro de los contenedores. La conexión de DuckDB usa un límite de memoria y una carpeta temporal, de modo que las operaciones grandes se desbordan a disco en lugar de fallar.

3.2. Descarga incremental de los datos

El script de descarga proporcionado tenía el año fijo en el código, usaba rutas relativas a la carpeta de ejecución, informaba un error de red como mes no publicado y no permitía verificar lo descargado. Se modificó para recibir los años como parámetro, calcular las rutas desde la ubicación del script, distinguir los errores de red de los meses aún no publicados, descargar la tabla de zonas de la TLC y verificar la completitud. La verificación compara cada mes publicado con el archivo local, exige que el tamaño coincida con el publicado y que el archivo se pueda abrir como Parquet, y guarda el diagnóstico en un manifiesto. El script omite los archivos existentes, por lo que puede ejecutarse de nuevo conforme la TLC publica meses nuevos. La Tabla 1 resume los archivos utilizados; de 2026 estaban publicados los meses de enero a agosto.

Tabla 1: Archivos descargados y verificados por año y tipo de taxi

Año	Tipo de taxi	Archivos	Registros	MB en disco
2024	Amarillo	12	41,169,720	693.0
2024	Verde	12	660,218	15.9
2025	Amarillo	12	48,722,602	830.0
2025	Verde	12	591,375	14.5
2026	Amarillo	8	29,703,355	511.5
2026	Verde	8	337,114	8.3
Total		64	121,184,384	2,073.1

3.3. Consultas directas y reglas de calidad

La exploración se hizo con consultas directas sobre los archivos. El inventario y los esquemas se obtuvieron leyendo solo los metadatos de Parquet, y la lectura de los datos se hizo con patrones glob por carpeta y la opción union_by_name, que une archivos con columnas distintas rellenando con nulos las ausentes. También se usaron DESCRIBE, muestreo reproducible y SUMMARIZE, que en una sola lectura calcula extremos, cuartiles y porcentaje de nulos de cada columna.

Sobre los archivos se construyeron tres capas. La vista viajes se genera automáticamente a partir del esquema real de los archivos: traduce los nombres de columnas de taxis amarillos y verdes a nombres comunes, convierte a un tipo común las columnas que varían y toma el año y mes del nombre del archivo. La vista viajes_calidad asigna a cada registro el primer motivo de exclusión que incumple según las reglas de la Tabla 2, sin modificar los archivos, y la vista viajes_validos contiene solo los registros sin motivo de exclusión, unidos con la tabla de zonas. Otros problemas que no invalidan un viaje, como pasajeros nulos o pago sin registro, se conservan con una etiqueta.

Tabla 2: Reglas de calidad aplicadas en orden a cada registro

Regla	Criterio de exclusión	Justificación
Fecha fuera del mes del archivo	La recogida no pertenece al año y mes del archivo	Relojes desconfigurados que distorsionan las series mensuales
Duración nula o negativa	El destino no es posterior a la recogida	Un viaje real tiene duración positiva
Duración mayor a 6 horas	Más de 360 minutos	Taxímetros que no se cerraron
Distancia cero	Distancia menor o igual a cero	Viajes cancelados o sin registro del taxímetro
Distancia mayor a 200 millas	Más de 200 millas	Imposible en una jornada urbana
Velocidad mayor a 80 mph	Distancia entre duración mayor a 80 mph	Combinación incoherente de distancia y tiempo
Monto negativo o ajuste	Tarifa o total negativos o nulos	Reembolsos y anulaciones contables
Total mayor a 1000 dólares	Total superior a 1000	Monto implausible para un taxi

Cada consulta se guarda en archivos SQL versionados con metadatos de objetivo, fuentes y decisión, y una bitácora registra automáticamente su resultado y tiempo en docs/consultas.md. Al terminar el laboratorio quedaron documentadas 86 consultas.

3.4. Preguntas de análisis

El análisis exploratorio de 2026 respondió nueve preguntas: la proporción de registros excluidos y su motivo; la evolución mensual de viajes e ingreso; las horas y tipos de día de mayor demanda y su efecto en la velocidad; las diferencias entre taxis amarillos y verdes en distancia, duración, pasajeros y monto; la distribución de las distancias; el reparto de los métodos de pago y la propina registrada; las zonas y distritos de origen; el peso de los viajes de aeropuerto; y los viajes válidos con una tarifa por milla atípica según el criterio de 1.5 veces el rango intercuartílico.

3.5. Diseño del benchmark

El benchmark comparó seis consultas con dos estrategias, leyendo los Parquet a través de la vista y leyendo una tabla DuckDB creada desde esa misma vista, por

lo que ambas procesan exactamente los mismos registros. Las consultas fueron un conteo total, un agregado mensual, un filtro selectivo de viajes de aeropuerto de más de 10 millas, un patrón horario con medianas, percentiles de distancia y monto, y una unión con la tabla de zonas. Se usaron cuatro volúmenes de los datos de 2024 y 2026: 1 mes, 3 meses, 12 meses y todos los meses. Cada consulta se ejecutó una vez de calentamiento y cinco veces medidas, y se reporta la mediana. También se registró el tiempo de creación de cada tabla y el espacio que ocupa, en una base separada, data/processed/benchmark.duckdb.

3.6. Indicadores y tablero

Se definieron trece preguntas e indicadores, listados en la Tabla 3. Cada indicador se calcula con una consulta SQL sobre la vista de viajes válidos y se guarda como una tabla en data/processed/tablero.duckdb, que incluye siempre el año para permitir comparaciones. Metabase se conecta a esa base en modo de solo lectura, de modo que el tablero no recalcula nada sobre los datos de detalle. Como un archivo DuckDB admite un solo proceso con escritura, Metabase se detiene mientras la base se reconstruye.

Tabla 3: Preguntas e indicadores del tablero

	Pregunta	Indicador
P1	Cuántos viajes e ingresos genera el servicio cada año	Volumen, ingreso y ticket promedio por año
P2	Cómo evoluciona mes a mes la demanda	Viajes por día en cada mes y tipo de taxi
P3	En qué horas se concentra la demanda	Viajes promedio por hora y tipo de día
P4	En qué horas el tráfico hace más lentos los viajes	Velocidad y duración mediana por hora
P5	Qué días tienen más viajes y viajes más caros	Viajes y ticket por día de la semana
P6	Cómo pagan los pasajeros	Participación de métodos de pago
P7	Qué propina se deja al pagar con tarjeta	Propina con tarjeta por franja horaria
P8	Desde qué zonas salen más viajes	Zonas de origen con más viajes
P9	Cómo se reparten los viajes entre distritos	Viajes e ingreso por distrito de origen
P10	Qué peso tienen los viajes de aeropuerto	Viajes e ingreso de aeropuerto
P11	Qué participación tienen los taxis verdes	Participación de amarillos y verdes
P12	Qué proporción de registros no es utilizable	Registros excluidos por regla de calidad
P13	Cómo cambian los recargos al pasajero	Recargos promedio por mes

4. Resultados

4.1. Disponibilidad y estructura de los archivos

Los 16 archivos de 2026 contienen 30,040,469 registros, y el conteo leído con read_parquet coincidió exactamente con el declarado en los metadatos. El inventario se resolvió en 0.06 s porque solo leyó el pie de cada archivo. La Figura 1 muestra la diferencia de escala entre los servicios: los taxis amarillos aportan el 98.9 % de los registros, con archivos de 3.3 a 4.1 millones de filas, mientras los verdes tienen de 37 a 45 mil filas por mes.

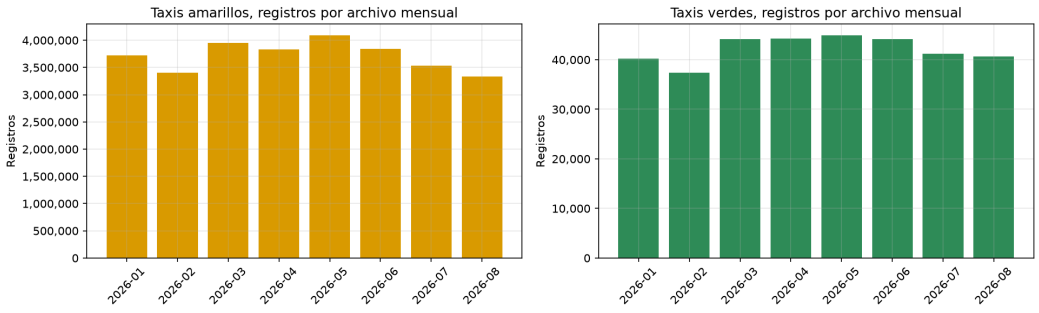


Figura 1: Registros por archivo mensual de 2026 para taxis amarillos y verdes

Los esquemas de ambos tipos comparten 18 columnas con el mismo nombre y tipo. Las diferencias son el prefijo de las fechas, tpep en amarillos y lpep en verdes, la columna Airport_fee, exclusiva de los amarillos, y ehail_fee y trip_type, exclusivas de los verdes. Dentro de 2026 la columna request_source aparece solo en 3 de los 8 archivos de cada tipo, y al incorporar los años anteriores se comprobó que cbd_congestion_fee existe desde 2025. La opción union_by_name y la vista generada desde el esquema absorbieron estas diferencias sin cambios en las consultas.

4.2. Calidad de los datos

SUMMARIZE recorrió los 29.7 millones de registros de taxis amarillos de 2026 en 28.9 s y reveló tres tipos de problemas. El primero es un faltante estructural: cinco columnas, entre ellas el número de pasajeros y el código de tarifa, tienen exactamente 25.98 % de nulos, y el código de pago 0 aparece en el mismo número de registros, 7,716,688; es decir, la fuente publica un grupo de viajes sin esos campos. El segundo son valores imposibles, como una distancia de 328,522 millas, tarifas entre −2,555 y 7,045 dólares y recogidas fechadas en 2001. El tercero son problemas frecuentes, resumidos en la Tabla 4 y la Figura 2.

Tabla 4: Porcentaje de registros de 2026 con cada problema de calidad

Problema	Amarillos, %	Verdes, %
Código de tarifa desconocido	28.57	14.47
Pago sin registro	25.98	14.47
Pasajeros nulos	25.98	14.47
Distancia cero	3.21	3.62
Destino no posterior a la recogida	1.25	0.07
Tarifa o total negativos	0.55	0.30
Pasajeros cero	0.31	1.34
Zona desconocida	0.17	0.34
Duración mayor a 6 horas	0.03	0.33
Distancia mayor a 200 millas	0.002	0.020
Fecha fuera del mes del archivo	0.000	0.029

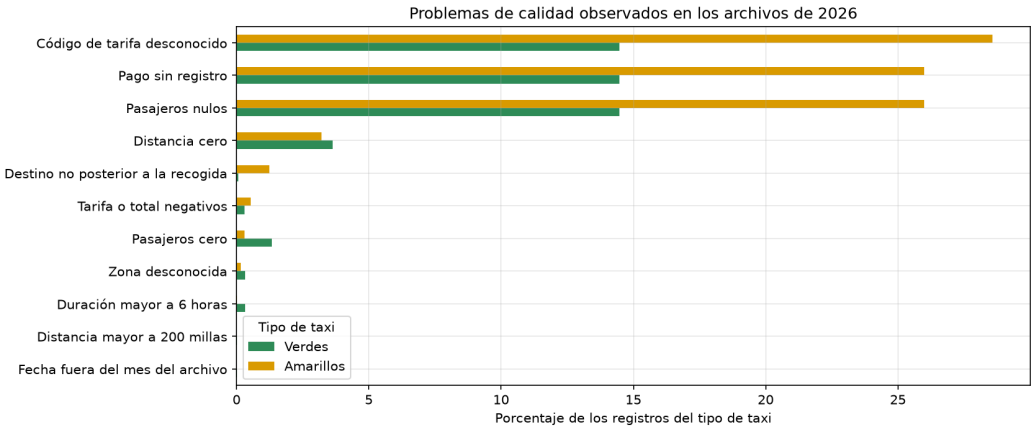


Figura 2: Porcentaje de registros de 2026 con cada problema de calidad por tipo de taxi

Al aplicar las reglas de la Tabla 2 se conservó el 95.04 % de los registros de taxis amarillos y el 95.52 % de los verdes, es decir, 28,229,225 y 322,011 viajes válidos. La exclusión más frecuente fue la distancia cero, con 3.17 % y 3.55 %, seguida en los amarillos por la duración nula o negativa, 1.25 %, y los montos negativos, 0.49 %. Las reglas extremas afectaron a menos del 0.03 % de los registros, pero eran las que distorsionaban los máximos y promedios.

4.3. Análisis exploratorio de 2026

4.3.1. Comportamiento temporal

La Figura 3 muestra una estacionalidad clara en los taxis amarillos: los viajes válidos por día suben de 113,424 en enero a un máximo de 126,187 en mayo y caen a 102,036

en agosto, 19 % menos que en mayo. El monto promedio por viaje se mantiene entre 29.67 y 30.60 dólares. Los taxis verdes se mueven entre 1,245 y 1,410 viajes por día, pero su monto promedio crece todos los meses, de 24.21 a 26.36 dólares.

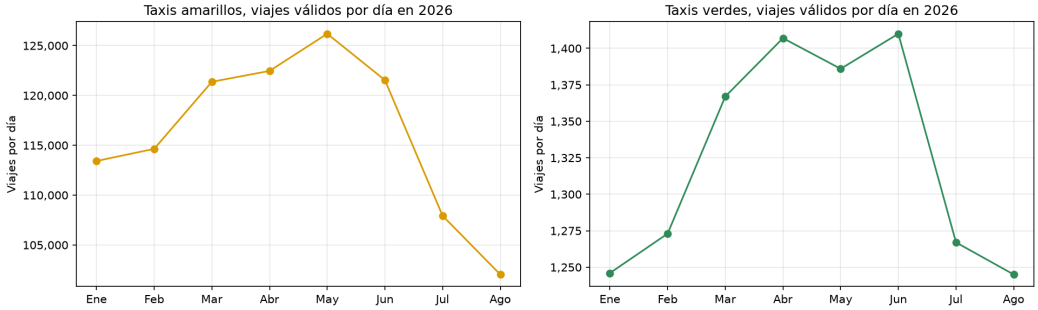


Figura 3: Viajes válidos promedio por día en cada mes de 2026 por tipo de taxi

El perfil horario de la Figura 4 distingue los tipos de día. Entre semana hay un mínimo cercano a 500 viajes por día a las 3 y 4 de la mañana, un pico a las 8 cercano a 5,800 y el máximo a las 18 horas con 7,740 viajes por día. En fin de semana desaparece el pico de la mañana, la medianoche concentra cerca de 6,900 viajes y el máximo, 7,393, también ocurre a las 18 horas. La velocidad mediana es el reflejo inverso de la demanda: entre semana pasa de cerca de 16.8 mph a las 4 de la mañana a valores entre 7.4 y 7.7 mph desde las 11 hasta las 17 horas, de modo que la congestión se extiende por casi toda la jornada laboral.

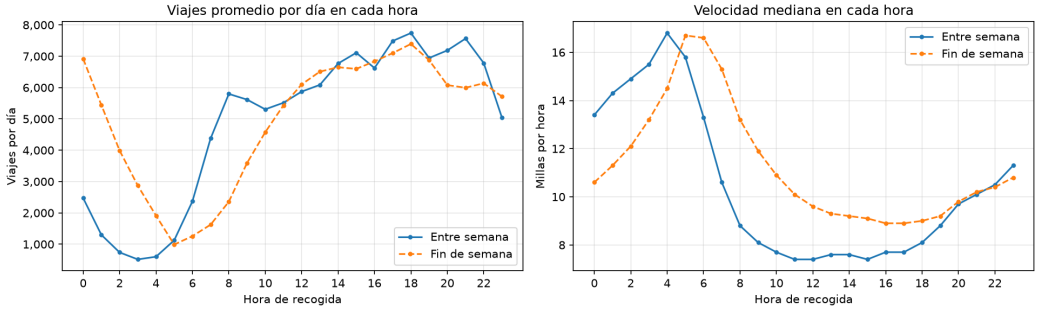


Figura 4: Perfil horario de la demanda y de la velocidad mediana en 2026, entre semana y fin de semana

4.3.2. Diferencias entre taxis amarillos y verdes

La Tabla 5 compara ambos servicios. El viaje típico de un taxi verde es algo más largo en distancia pero más corto en tiempo y más barato. La Figura 5 muestra que los verdes tienen menos viajes muy cortos, mientras que los amarillos tienen una cola larga mayor, explicada por los viajes al aeropuerto.

Tabla 5: Características de los viajes válidos de 2026 por tipo de taxi

Indicador	Amarillos	Verdes
Viajes válidos	28,229,225	322,011
Pasajeros promedio	1.25	1.30
Distancia, percentil 25, millas	1.10	1.33
Distancia mediana, millas	1.93	2.15
Distancia, percentil 99, millas	19.52	17.73
Duración mediana, minutos	14.1	13.4
Total mediano, USD	23.58	20.52
Viajes de aeropuerto, %	8.16	3.35
Pago con tarjeta, %	65.37	65.51
Pago en efectivo, %	9.06	19.40
Pago sin registro, %	24.95	14.79
Propina mediana con tarjeta, % de la tarifa	26.38	23.55
Tarifa por milla atípica, %	5.18	13.34

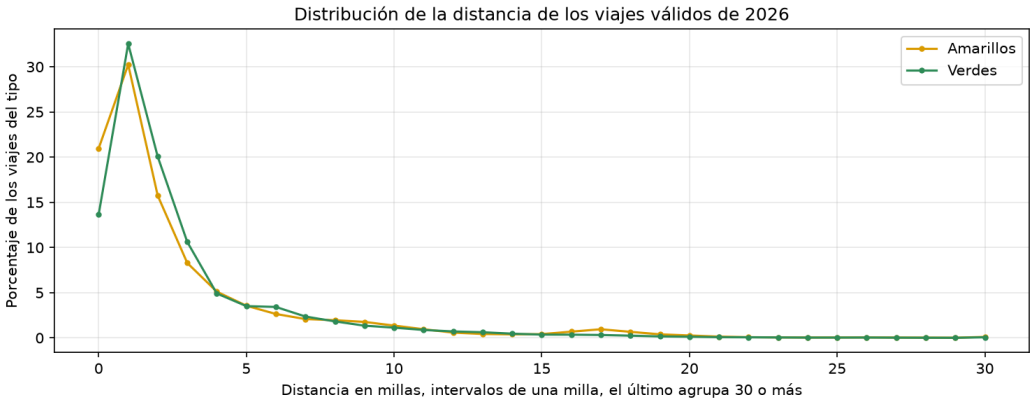


Figura 5: Distribución de la distancia de los viajes válidos de 2026 por tipo de taxi

La geografía explica la diferencia. Los diez orígenes principales de los taxis amarillos son zonas de Manhattan, salvo el aeropuerto JFK en tercer lugar, y la zona más frecuente concentra solo el 4.44 % de los viajes. En los verdes, East Harlem North y East Harlem South concentran el 40 % de los viajes, y el resto de los orígenes principales están en el norte de Manhattan, Queens y Brooklyn. En los amarillos, los viajes a JFK tienen una mediana de 16.9 millas y 89.21 dólares y los de Newark de 131.68 dólares, frente a 22.45 dólares de un viaje sin aeropuerto.

4.3.3. Pago, propina y valores atípicos

La tarjeta tiene una participación casi idéntica en ambos servicios, cerca del 65 %, pero los pasajeros de taxis verdes pagan en efectivo con el doble de frecuencia, 19.40 % frente a 9.06 %. La propina solo es observable con tarjeta: con ese método el 91 % de los viajes registra propina, mientras en efectivo prácticamente ninguno lo hace porque el taxímetro no la captura. La Figura 6 resume ambos aspectos.

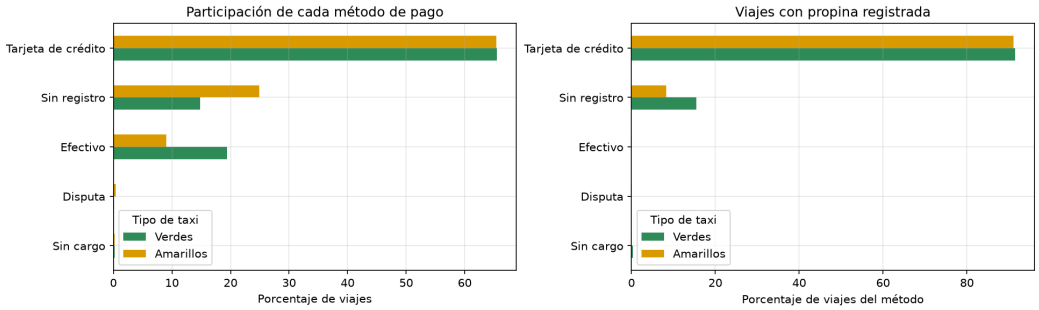


Figura 6: Métodos de pago y proporción de viajes con propina registrada en 2026 por tipo de taxi

El criterio del rango intercuartílico marcó como atípica la tarifa por milla del 5.18 % de los viajes válidos amarillos, todos por encima del límite de 16.11 dólares por milla, y del 13.34 % de los verdes, con 14,419 atípicos altos y 28,201 bajos. Estos viajes cumplen las reglas de calidad, lo que muestra que una relación coherente entre distancia y tiempo no garantiza una relación coherente entre distancia y monto. Los atípicos altos corresponden previsiblemente a viajes cortos y lentos, donde pesan más la bajada de bandera y el cobro por tiempo.

4.4. Incorporación de 2024

Al ejecutar el script con 2024 y 2026 se descargaron solo los 24 archivos de 2024 y se omitieron los existentes. Las capas se regeneraron sin cambios en el código y la vista conjunta leyó exactamente los 71,870,407 registros declarados en los metadatos de los 40 archivos, sin diferencias en ningún archivo. Las nueve consultas del análisis exploratorio se ejecutaron sin modificaciones. La Figura 7 compara los meses comunes: los taxis amarillos tienen más viajes en todos los meses de 2026, con un aumento de 22.64 % en enero que se reduce a 6.43 % en junio, mientras los verdes tienen entre 18 % y 29 % menos viajes que en el mismo mes de 2024.

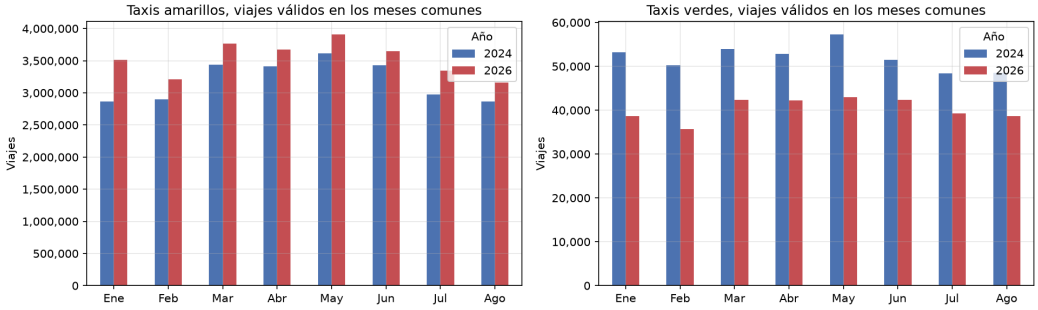


Figura 7: Viajes válidos por mes en los meses disponibles tanto en 2024 como en 2026

4.5. Benchmark entre Parquet y tablas materializadas

La tabla materializada fue más rápida en todas las consultas y volúmenes, pero la ventaja depende del tipo de consulta, como muestra la Tabla 6. El filtro selectivo fue entre 6.4 y 12.7 veces más rápido sobre la tabla, el agregado mensual y la unión con zonas entre 2.5 y 3.4 veces, y los percentiles apenas entre 1.0 y 1.4 veces, porque su costo está dominado por ordenar los datos y no por leerlos. El conteo total tiene cocientes altos, pero en tiempos absolutos ambas estrategias son casi instantáneas.

Tabla 6: Cociente entre el tiempo sobre Parquet y el tiempo sobre la tabla DuckDB

Consulta	1 mes	3 meses	12 meses	Todos los meses
Conteo total	16.71	22.72	35.11	29.06
Agregado mensual	2.55	3.02	2.99	3.43
Filtro selectivo	12.67	8.34	6.39	8.83
Patrón horario	2.73	2.02	1.30	2.41
Percentiles	1.31	1.03	1.23	1.40
Unión con zonas	3.00	2.55	3.19	2.76

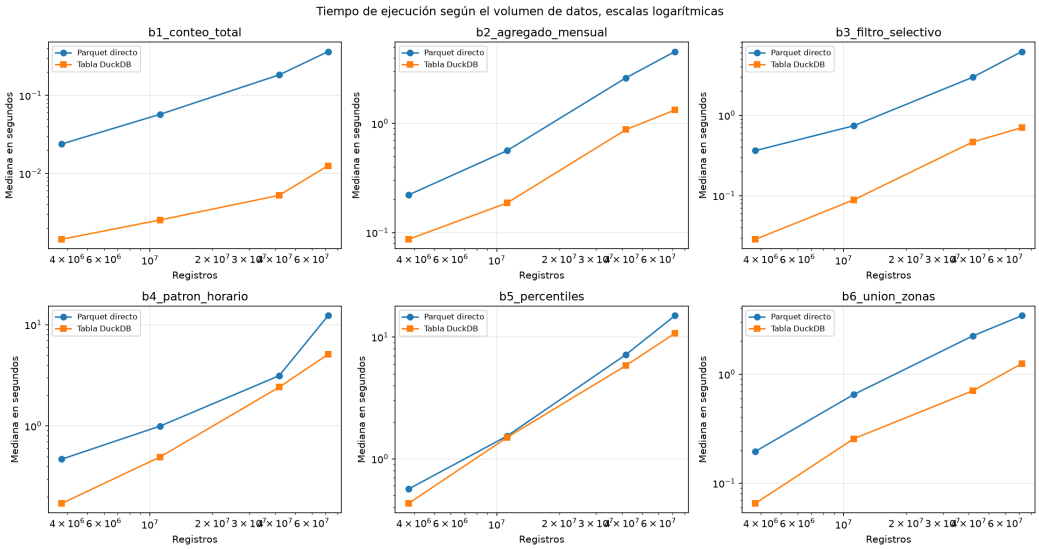


Figura 8: Mediana del tiempo de cada consulta del benchmark según el volumen, Parquet directo frente a tabla DuckDB

La Figura 8 muestra que con ambas estrategias el tiempo crece de forma aproximadamente proporcional al número de registros: de 1 mes a todos los meses los registros se multiplican por 19 y el agregado mensual sobre Parquet pasa de 0.22 s a 4.56 s. Por eso la Figura 9 no muestra una tendencia clara del cociente con el volumen; la ventaja de la tabla es un factor más o menos constante por tipo de consulta.

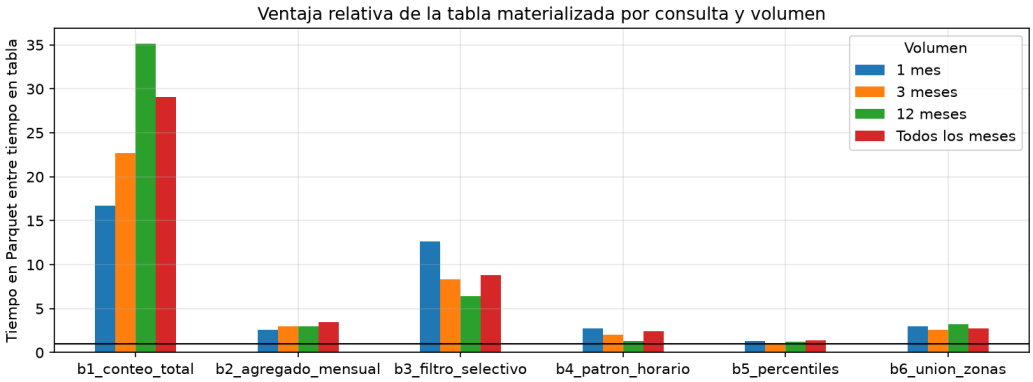


Figura 9: Cociente entre el tiempo sobre Parquet y el tiempo sobre la tabla DuckDB por consulta y volumen

La Tabla 7 pone esa ventaja frente al costo de materializar. Con todos los meses la tabla tardó 93.1 s en crearse y ocupa 2,584 MB, 2.1 veces el tamaño de los Parquet, porque el formato interno de DuckDB comprime menos y guarda también las columnas que agrega la vista. Con el ahorro medido por cada ejecución de las seis consultas, la creación se recupera en cuatro a cinco ejecuciones en todos los volúmenes.

Tabla 7: Costo de materializar y tiempo total de las seis consultas

Volumen	Registros	Tamaño, MB		Creación	Seis consultas, s		Ejecuciones
		Parquet	Tabla	s	Parquet	Tabla	para amortizar
1 mes	3,765,161	65.2	134.0	5.0	1.84	0.78	4.8
3 meses	11,199,059	193.7	401.3	10.5	4.55	2.52	5.2
12 meses	41,829,938	708.9	1,496.1	41.2	18.35	10.31	5.1
Todos	71,870,407	1,228.6	2,584.0	93.1	41.80	19.11	4.1

4.6. Indicadores y tablero en Metabase

El tablero Viajes de Taxi de Nueva York se organizó en tres secciones: un resumen con los indicadores generales, los viajes por día, la participación por tipo y la serie mensual; los patrones de tiempo, con demanda y velocidad por hora y viajes por día de la semana; y el pago, la geografía y la calidad, con métodos de pago, propina, zonas, distritos, aeropuertos, registros excluidos y recargos. Un filtro de año conectado a todas las tarjetas permite comparar periodos. La Figura 10 muestra el tablero actualizado con los tres años; las capturas de cada tarjeta están en las carpetas docs/tablero/e7 y docs/tablero/e8 del repositorio.

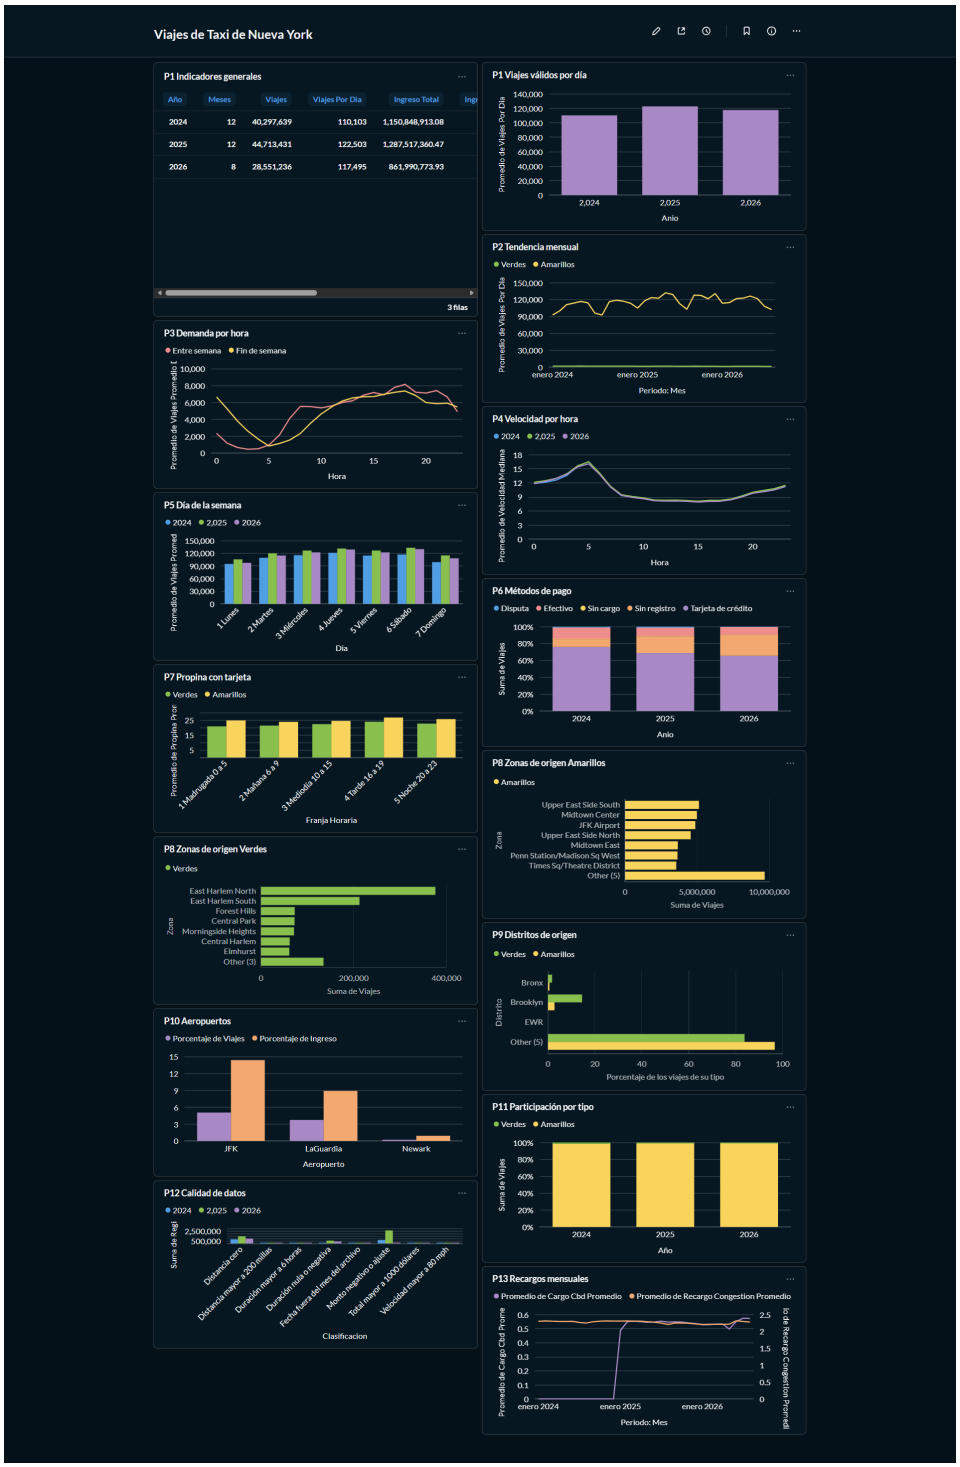


Figura 10: Tablero de Metabase con los indicadores de 2024, 2025 y 2026

Con 2024 y 2026, el tablero muestra que en 2026 hay 6.7 % más viajes válidos por día y 12.8 % más ingreso por día, porque el ticket promedio también sube. La demanda alcanza su máximo a las 18 horas y la velocidad baja a cerca de 8 mph entre las 11 y las 17 horas en ambos años; jueves y sábado son los días con más viajes. Cerca del 88 % de los viajes amarillos sale de Manhattan, frente a cerca del 60 % de los verdes, que tienen alrededor del 23 % en Queens y del 14 % en Brooklyn. Los aeropuertos

suman cerca del 9 % de los viajes y cerca del 24 % del ingreso. La propina con tarjeta se mantiene entre 23 % y 27 % en los amarillos según la franja, con el máximo en la tarde. Las Figuras 11 y 12 reproducen los mismos indicadores con Matplotlib a partir de la base que lee Metabase.

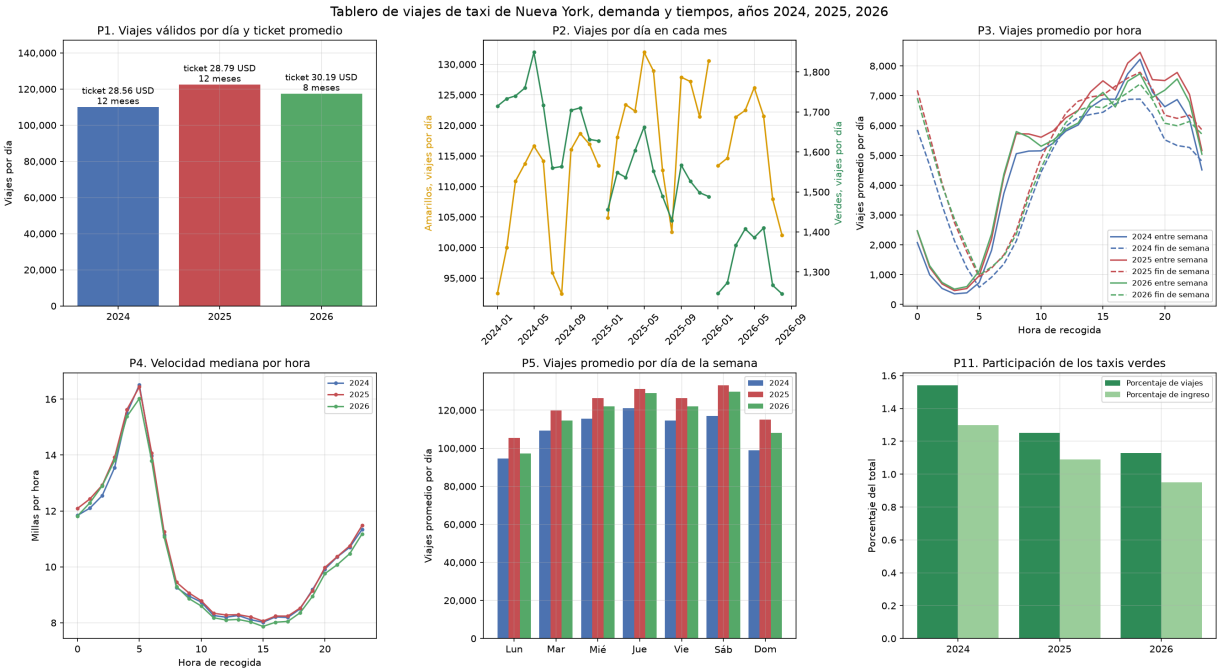


Figura 11: Indicadores de demanda, tiempos y participación por tipo de taxi, años 2024, 2025 y 2026

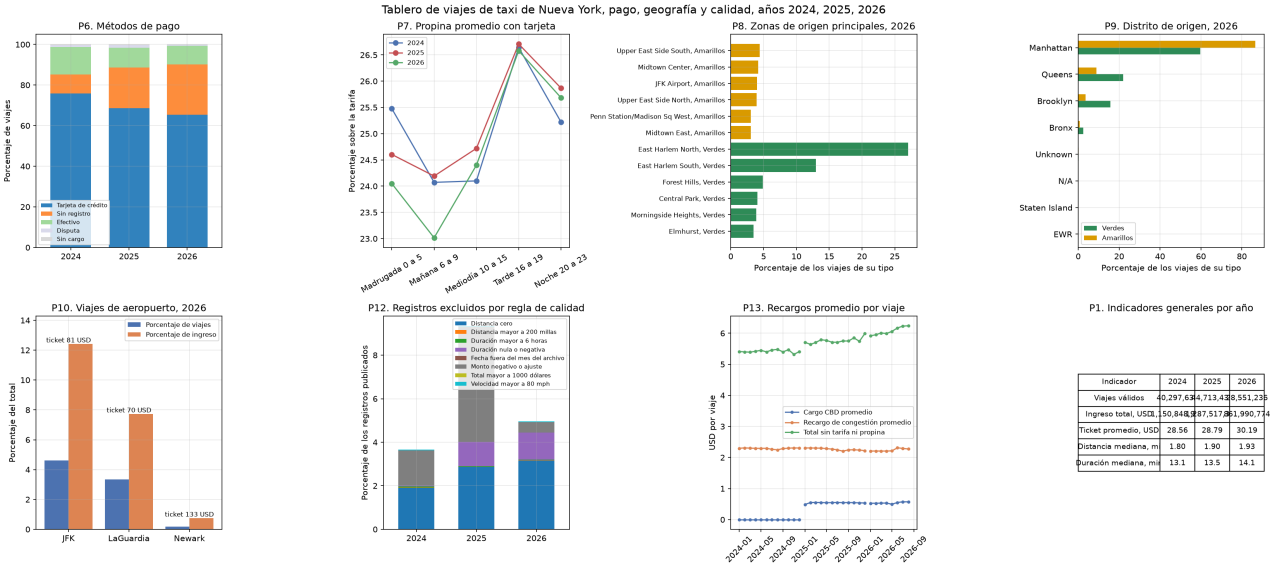


Figura 12: Indicadores de pago, geografía, aeropuertos, calidad y recargos, años 2024, 2025 y 2026

4.7. Evolución entre 2024 y 2026

Al incorporar 2025 se descargaron solo sus 24 archivos, la vista conjunta leyó los 121,184,384 registros de los 64 archivos sin diferencias con los metadatos y todas las consultas, el benchmark y los indicadores funcionaron sin cambios. La Tabla 8 resume la evolución de los indicadores principales.

Tabla 8: Indicadores de los viajes válidos por año; 2026 incluye de enero a agosto

Indicador	2024	2025	2026
Registros publicados	41,829,938	49,313,977	30,040,469
Registros válidos, %	96.34	90.67	95.04
Viajes válidos por día	110,103	122,503	117,495
Ingreso por día, USD	3,144,396	3,527,445	3,547,287
Total promedio por viaje, USD	28.56	28.79	30.19
Tarifa promedio, USD	19.77	19.99	21.24
Distancia mediana, millas	1.80	1.90	1.93
Duración mediana, minutos	13.07	13.52	14.10
Velocidad mediana, mph	9.30	9.45	9.29
Pago con tarjeta, %	75.91	68.68	65.37
Pago sin registro, %	9.23	19.88	24.83
Propina con tarjeta, %	25.12	25.43	25.07
Participación de taxis verdes, %	1.54	1.25	1.13
Viajes amarillos con cargo CBD, %	0.00	73.03	72.39

A partir de los tres años se identificaron los siguientes patrones.

- La demanda creció 11.3 % en 2025 y se estabilizó en 2026. La caída de 4.1 % de 2026 está sesgada porque faltan septiembre a diciembre, que en 2025 fueron meses altos; mes a mes, la Figura 13 muestra que 2026 supera a 2025 en enero y queda ligeramente por debajo en la mayoría de los meses siguientes. La estacionalidad se repite en los tres años.
- Cada viaje es más caro. El total promedio sube de 28.56 a 30.19 dólares y los cargos distintos de tarifa y propina pasan de 5.45 a 6.07 dólares por viaje en los amarillos y de 3.41 a 6.04 en los verdes. Desde 2025 aparece el cargo de congestión CBD, presente en el 73 % de los viajes amarillos con un promedio de 0.55 dólares.
- Los viajes son más largos pero no más lentos. La duración y la distancia medianas crecen cerca de 8 %, mientras la velocidad mediana se mantiene

entre 9.29 y 9.45 mph. El perfil horario se aplana: la hora de las 18 pasa de concentrar el 7.1 % de los viajes del año en 2024 a cerca del 6.5 % en 2026.

- El registro del pago se deteriora. La tarjeta baja del 75.91 % al 65.37 % y los viajes sin método de pago suben del 9.23 % al 24.83 %. Como la propina con tarjeta se mantiene cerca del 25 %, el cambio parece un problema creciente de captura en la fuente más que un cambio de comportamiento.
- Los taxis verdes pierden participación, del 1.54 % al 1.13 % de los viajes, con menos viajes por día en cada mes de cada año.
- La calidad varía entre años. En 2025 solo el 90.67 % de los registros es válido, con 5.29 % de montos negativos o ajustes y 1.11 % de duraciones nulas o negativas, y la distancia cero crece de 1.91 % en 2024 a 3.17 % en 2026.

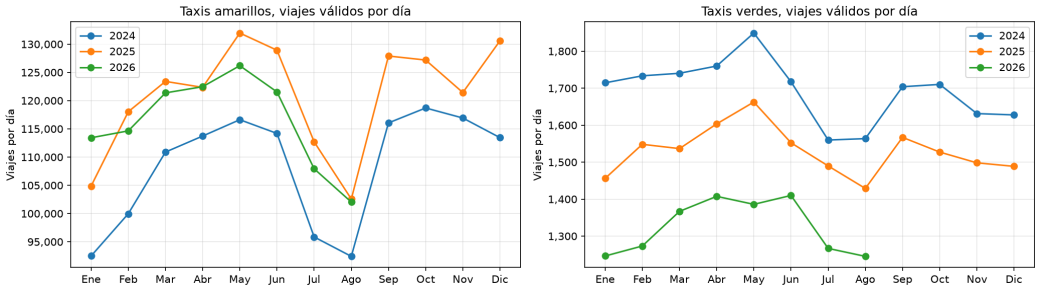


Figura 13: Viajes válidos por día en cada mes, comparación de 2024, 2025 y 2026 por tipo de taxi

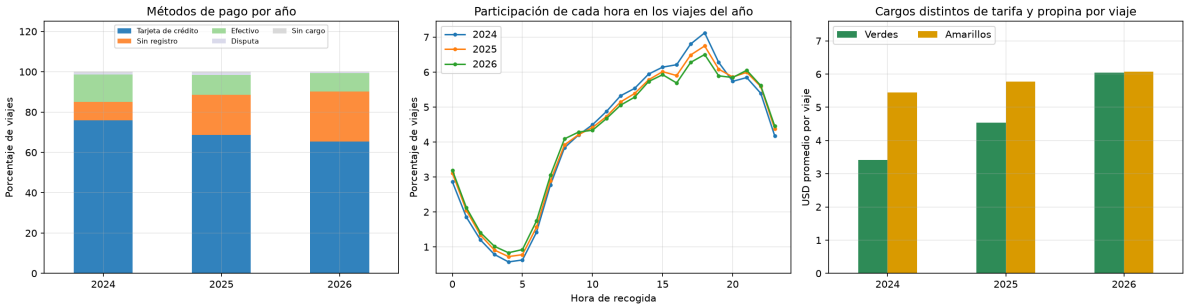


Figura 14: Evolución de métodos de pago, perfil horario y recargos por viaje entre 2024 y 2026

La Tabla 9 detalla los recargos por tipo de taxi. El recargo de congestión general se mantiene estable y el aumento de los cargos distintos de tarifa se explica en buena parte por el cargo CBD, que en los verdes aparece en menos del 10 % de los viajes porque operan mayormente fuera de la zona de congestión.

Tabla 9: Recargos promedio por viaje válido, en dólares, por año y tipo de taxi

Año	Tipo	Con cargo CBD, %	Cargo CBD	Congestión	Cargos no tarifa	Total
2024	Amarillo	0.00	–	2.317	5.45	28.63
2024	Verde	0.00	–	0.856	3.41	24.10
2025	Amarillo	73.03	0.548	2.285	5.78	28.84
2025	Verde	9.62	0.073	0.913	4.54	25.14
2026	Amarillo	72.39	0.543	2.256	6.07	30.25
2026	Verde	8.50	0.064	0.915	6.04	25.38

5. Discusión

5.1. Parquet directo frente a tablas materializadas

Consultar los Parquet directamente evita la carga y la copia de los datos, lee solo las columnas necesarias, aprovecha las estadísticas de los archivos y deja disponibles los datos nuevos en cuanto se descargan. Su limitación es que cada consulta repite la lectura, la descompresión y las conversiones de la vista, lo que en el benchmark duplicó el tiempo total de las consultas repetidas. La tabla materializada elimina ese costo y ofrece un esquema estable que otras herramientas pueden abrir, pero exige tiempo de creación, el doble de espacio y reconstruirse cada vez que llegan archivos nuevos.

La estrategia adecuada depende del uso. Para explorar, para consultas que se ejecutan pocas veces y para datos que cambian con frecuencia conviene consultar Parquet. Para un conjunto que se consulta muchas veces, como un análisis iterativo, conviene materializar, porque la creación se recupera en pocas ejecuciones. La solución usada en el tablero combina ambas: el detalle permanece en Parquet y solo se materializan los agregados que Metabase consulta repetidamente, lo que produce una base pequeña y rápida.

5.2. DuckDB frente a Pandas

Con Pandas habría sido necesario cargar en memoria todas las filas y columnas antes de calcular, y los tres años ocupan varias veces la memoria de un equipo personal una vez descomprimidos. Con DuckDB solo el resultado de cada consulta llegó a Pandas, tablas de decenas o cientos de filas, mientras el cálculo se ejecutó en paralelo con lectura selectiva de columnas y desborde a disco. Además, las consultas

quedaron escritas en SQL versionado y documentado, reutilizable desde el notebook, los scripts y el tablero.

5.3. Incorporación de datos con cambios mínimos

Incorporar 2024 y 2025 consistió en ejecutar el script de descarga con otros años y regenerar las capas. Esto fue posible por cuatro decisiones de diseño: el script incremental recibe los años como parámetro; los archivos se organizan por tipo y año y se leen con patrones glob; la vista se genera desde el esquema real de los archivos, lo que absorbió columnas nuevas como cbd_congestion_fee; y todo el análisis consulta vistas que incluyen el año del archivo en lugar de archivos concretos.

5.4. Limitaciones

Los resultados de 2026 cubren solo de enero a agosto, por lo que las comparaciones anuales se hicieron con viajes por día, promedios y medianas, y aun así la estacionalidad introduce un sesgo frente a años completos. La proporción creciente de viajes sin método de pago limita el análisis de pagos y obliga a calcular la propina solo con tarjeta. La calidad de los registros cambió entre años, en especial en 2025, por lo que las reglas deben recalcularse con cada incorporación. Finalmente, los tiempos del benchmark dependen del equipo; lo comparable son los cocientes entre estrategias.

5.5. Automatización en producción

En un ambiente de producción deberían automatizarse la descarga mensual con la verificación de completitud como condición para continuar, la validación del esquema de cada archivo nuevo, el cálculo de las reglas de calidad con alertas ante cambios bruscos en la proporción excluida, la reconstrucción de la base de indicadores mediante un intercambio atómico que no requiera detener el tablero y el registro de cada ejecución con los archivos procesados.

6. Conclusiones

DuckDB permitió analizar 121,184,384 registros de tres años directamente sobre 64 archivos Parquet desde un equipo personal, sin servidor de base de datos y sin cargar los datos en memoria con Pandas. Los conteos de la vista conjunta coincidieron con

los metadatos en todos los archivos, lo que confirma que la lectura conjunta no pierde ni duplica registros.

El diseño incremental hizo que incorporar 2024 y 2025 no requiriera modificar ninguna consulta del análisis, del benchmark ni de los indicadores. El tablero de Metabase se actualizó al reconstruir la base de indicadores con las mismas tablas.

La calidad de los datos exige reglas explícitas y revisadas en cada incorporación. Entre el 90.67 % y el 96.34 % de los registros de cada año es válido, la distancia cero es la exclusión más frecuente en 2024 y 2026, y una cuarta parte de los registros de taxis amarillos de 2026 llega sin método de pago.

El servicio está dominado por los taxis amarillos, concentrado en Manhattan y en los aeropuertos, con una estacionalidad estable y un pico diario a las 18 horas. Entre 2024 y 2026 aumentaron los viajes por día, el monto por viaje y la duración de los viajes, mientras los taxis verdes perdieron participación y el cargo de congestión CBD se incorporó desde 2025 a casi tres de cada cuatro viajes amarillos.

Materializar una tabla en DuckDB aceleró todas las consultas del benchmark y ahorró 22.7 s por ejecución del conjunto con todos los meses, a cambio de 93.1 s de creación y del doble de espacio. Consultar Parquet es la opción adecuada para explorar y para datos que cambian, y materializar lo es para los agregados que se consultan repetidamente, como la base de indicadores del tablero.

7. Referencias

- New York City Taxi & Limousine Commission. TLC Trip Record Data. `https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page`
- New York City Taxi & Limousine Commission. Data Dictionary, Yellow Taxi Trip Records y Green Taxi Trip Records. `https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page`
- DuckDB. Documentación de DuckDB, lectura de archivos Parquet. `https://duckdb.org/docs/data/parquet/overview`
- Metabase. Documentación de Metabase. `https://www.metabase.com/docs/latest/`
- MotherDuck. Controlador de DuckDB para Metabase. `https://github.com/motherduckdb/metabase_duckdb_driver`